عنوان پروژه: اعتبارسنجی مشتریان (Credit Risk Scoring)

با سلام و احترام،

از این که تا به این‌جای مسیر رو در کنار ما بودید بسیار خوشحالیم. در پروژه پیش‌رو قصد شده است تا با طی کردن مسیری ساده و شفاف، با نگاه شما برای حل مسئله، رفع چالش‌های موجود، تحلیل نتایج و ارائه گزارش به ذینفعان آشنا شویم. صمیمانه از زمانی که در این مسیر طی خواهید کرد سپاسگزاریم.

تعریف مسئله

فرض کنید تیم ریسک اعتباری قصد دارد مدلی اولیه برای پیش‌بینی احتمال نکول مشتریان و رتبه‌بندی ریسک آن‌ها توسعه دهد.
به شما یک دیتاست خام (در پیوست این فایل) داده شده است، لطفا گام‌های زیر را به ترتیب انجام دهید:

1. پاک‌سازی داده‌ها و تحلیل اکتشافی (Data Cleaning & EDA)

- هدف از این گام: درک ساختار داده‌های خام آلمانی (German Credit)، مدیریت چالش‌های اولیه داده‌های واقعی و استخراج بینش‌های اولیه است:

- نام‌گذاری و آماده‌سازی اولیه: بارگذاری فایل خام، اعمال نام ستون‌ها بر اساس مستندات (german.doc) و تبدیل متغیر هدف (Target) به فرمت استاندارد (0 برای مشتریان خوش‌حساب و 1 برای مشتریان نکول‌کرده/بدحساب).

- بررسی کیفیت و نوع داده‌ها: تفکیک دقیق ویژگی‌های کمی (Numerical) و کیفی/دسته‌ای (Categorical) و بررسی مقادیر گمشده (Missing Values).

- توزیع‌ها و داده‌های پرت (Outliers): بررسی توزیع ویژگی‌های کلیدی مانند مبلغ وام (Credit Amount) و مدت زمان تسهیلات (Duration) به کمک نمودارهایی نظیر Boxplot و Histogram برای شناسایی مقادیر پرت.

- تحلیل ارتباطات (Correlation & Association): بررسی همبستگی متغیرهای عددی و تحلیل ارتباط ویژگی‌های کیفی مهم (مانند وضعیت حساب جاری Checking Account یا سابقه اعتباری Credit History) با متغیر هدف (نکول).

• خروجی مورد انتظار:

۱. گزارشی کوتاه از تعداد نمونه‌ها، ویژگی‌ها و وضعیت نامتعادل بودن کلاس هدف (Imbalance Ratio).

۲. حداقل ۲ نمودار کلیدی (ترکیبی از تصویری و متنی) که نشان دهد کدام ویژگی‌های خام بیشترین ارتباط اولیه را با نکول دارند.

2. مهندسی ویژگی و پیش‌پردازش (Feature Engineering & Preprocessing)

• هدف از این گام: آماده‌سازی داده‌ها با رعایت اصول عدم نشت اطلاعات و ساخت ویژگی‌های معنادار مالی است:

- تفکیک داده (Train/Test Split): جداسازی داده‌ها باید پیش از هرگونه پیش‌پردازش انجام شود تا نشت داده (Data Leakage) رخ ندهد؛ کلیه ترانسفورمرها باید صرفا روی دیتای Train برازش (Fit) شوند.

- پاک‌سازی و آماده‌سازی: مدیریت داده‌های گمشده (Missing Values)، کدگذاری متغیرهای دسته‌ای (Encoding) و مقیاس‌بندی مناسب (Scaling) در صورت نیاز به مدل.

- خلق ویژگی‌های مالی معنادار (Financial Feature Creation): استفاده از دانش دامنه برای ساخت نسبت‌های اعتباری کلیدی (مانند نسبت تعهدات به درآمد، نسبت استفاده از حد اعتباری، یا شاخص‌های ثبات رفتار مالی).

• خروجی مورد انتظار:

۱. گزارش نحوه مدیریت داده‌های از دست رفته و منطق انتخابی برای انکودینگ متغیرها.

۲. معرفی حداقل یک یا دو ویژگی جدید خلق‌شده همراه با فرمول و توجیه منطقی اثر آن بر ریسک.

۳. تحلیل و معرفی ۳ ویژگی کلیدی که به نظر شما بیشترین قدرت تفکیک مشتریان خوش‌حساب از بدحساب را دارند (همراه با استدلال تحلیلی).

3. مدل‌سازی و توضیح‌پذیری (Modeling & Explainability)

الف) پیاده‌سازی و مقایسه مدل‌ها

هدف از این گام ساخت یک ساختار بنچمارک، تنظیم هایپرپارامترها و ارزیابی منصفانه مدل‌ها بر اساس واقعیت‌های داده نامتوازن (Imbalanced Data) است:

- مدل پایه (Baseline): پیاده‌سازی یک مدل تک‌درخت ساده و تفسیرپذیر (DecisionTree) با محدود کردن عمق برای جلوگیری از بیش‌برازش.
- مدل پیشرفته (Challenger): پیاده‌سازی یک مدل مبتنی بر یادگیری جمعی مانند Random Forest (یا الگوریتم‌های گرادیان بوستینگ نظیر XGBoost).
- تنظیم هایپرپارامترها (Hyperparameter Tuning): بهینه‌سازی پارامترهای کلیدی به کمک Cross-Validation.
- خروجی مورد انتظار:

- جدول مقایسه عملکرد مدل‌ها روی دیتای Test شامل متریک‌های ROC-AUC و PR-AUC (با توجه به فراوانی کم کلاس نکول).
- رسم Confusion Matrix برای مدل نهایی بر اساس یک Cut-off مشخص، همراه با تحلیل توازن میان نرخ خطاها (False Positive در برابر False Negative).

ب) باز کردن جعبه سیاه با هوش مصنوعی توضیح‌پذیر (XAI)

هدف از این گام استخراج منطق تصمیم‌گیری مدل در دو سطح کلان و خرد است:

- تحلیل سراسری (Global Explanation - الزامی): استفاده از مقادیر SHAP (مانند نمودار Beeswarm و Bar Plot) برای شناسایی متغیرهای دارای بیشترین اثر مثبت و منفی بر تصمیم مدل.

- تحلیل موردی (Local Explanation - الزامی): تحلیل رفتار مدل برای حداقل ۲ نمونه خاص (مثلاً یک مشتری کم‌ریسک تاییدشده و یک مشتری پرریسک ردشده) به کمکWaterfall Plot یا Force Plot از کتابخانه SHAP.
- LIME (اختیاری): مقایسه خروجی تقریب محلی LIME با نتایج SHAP در یک پرونده خاص.

ج) کاربرد مدل‌های زبانی بزرگ - LLM (بخش امتیازی و پیشرفته - اختیاری)

در صنعت لندتک و بانکداری، مشتریان ردشده حق دارند دلایل رد درخواست خود را شفاف و ساده بدانند (قانون رگولاتوری Adverse Action).

- چالش: نمودارها و اعداد خروجی SHAP برای مشتری یا کارشناس شعبه غیرقابل‌فهم هستند.
- سناریو: یک پرامپت (Prompt) فرضی طراحی کنید که خروجی عددی SHAP یک مشتری ردشده را به مدل زبانی داده و از آن بخواهد:

۱. با زبانی محترمانه، ساده و عاری از اصطلاحات فنی به مشتری بگوید چه عواملی باعث رد درخواست شدند.

۲. راهکارهای مشخص و عملیاتی برای بهبود وضعیت اعتباری او در ماه‌های آینده پیشنهاد دهد.

- خروجی مورد انتظار: نمایش پرامپت پیشنهادی و نمونه متن تولیدشده توسط LLM (می‌توانید پاسخ را به صورت دستی یا تستی از طریق ChatGPT استخراج کرده و پیوست کنید).

4. تحلیل علیت در برابر همبستگی (Causality vs. Correlation)

هدف از این گام: سنجش تفکر نقادانه و تمایز میان «همبستگی آماری» و «علت واقعی ریسک» برای تصمیم‌گیری کسب‌وکار است. لطفا به سوالات زیر پاسخ تحلیلی دهید:

1. تفسیر علت و معلول: با نگاه به خروجی مدل و مقادیر SHAP، کدام متغیرها مستقیما علت تغییر ریسک هستند و کدام صرفا نشانه‌های همبسته (علامت/نشانه) هستند؟

(مثال راهنما: آیا بالا بودن سن یا داشتن تحصیلات بالا خودش ذاتا مانع نکول می‌شود، یا عواملی پنهان مانند «ثبات شغلی و درآمد بالاتر» وجود دارند که هم با تحصیلات مرتبطاند و هم با نکول؟ به این عوامل پنهان اثرگذار در آمار متغیر مخدوش‌گر یا Confounder می‌گویند).

2. تصمیم‌گیری عملیاتی: اگر مدیر ریسک بخواهد برای کاهش نکول دست به مداخله بزند (مثلا پیشنهاد دوره‌های آموزشی به کاربر، یا تغییر سقف اعتبار و نرخ سود)، روی کدام دسته از متغیرها می‌تواند سیاست‌گذاری کند؟ چرا اتکا به متغیرهای صرفا همبسته می‌تواند برای بانک خطرناک باشد؟

5. گزارش نهایی

تحویل پروژه شامل دو بخش اصلی و مکمل است:

الف) نوت‌بوک فنی (Code & Implementation - پسوند ipynb یا پایتون)
این فایل باید کاملا خوانا، ساختاریافته و دارای کامنت باشد و کلیه مراحل شامل موارد زیر را به صورت Reproducible اجرا کند:

- پاک‌سازی، تفکیک بدون نشت (Train/Test Split) و مهندسی ویژگی.
- آموزش مدل پایه (Baseline) و مدل پیشرفته همراه با ارزیابی دقیق (Confusion Matrix, ROC-AUC, PR-AUC).
- پیاده‌سازی کدهای مربوط به SHAP/XAI و ترسیم نمودارهای تحلیلی (Beeswarm, Waterfall یا Force plot).
- پاسخ تشریحی کوتاه به پرسش بخش علیت (Causality) در یک سلول متنی (Markdown).

ب) گزارش سیاستی/مدیریتی برای ذینفعان (Executive Business Report - حداکثر ۳ الی ۴ صفحه در قالب PDF)
این سند ویژه مدیران ارشد ریسک و محصول طراحی می‌شود و باید لحنی تجاری، شفاف و بدون درگیر شدن در کد داشته باشد. ساختار پیشنهادی:
۱. خلاصه مدیریتی: هدف پروژه، رویکرد و نتیجه کلی در یک پاراگراف.

۲. تحلیل کلیدی داده: ۲ الی ۳ نمودار مهم از توزیع مشـــتریان بدحســـاب و رفتار آن‌ها همراه با نتیجه‌گیری بیزینسی.

۳. مقایســه و انتخاب مدل نهایی: جدول مقایســه مدل‌ها با تکیه بر هزینه بیزینســی (Trade-off) بین از دست دادن مشتری خوب و پذیرش مشتری پرریسک).

۴. ریشه‌یابی ریسک و توضیح‌پذیری: توضیح چرایی خروجی مدل با استفاده از نتایج SHAP به زبانی که مدیر شعبه/ریسک بتواند به مشتری معترض توضیح دهد.

با تشکر

شرکت هوش مصنوعی پارت

تیم اعتبارسنجی